准确率、精确率、召回率、F1-score 值的原理

在机器学习中，要评估一个模型在任务中的优越性，需要利用评价指标来对其进行评估，而评价指标往往有多个，从不同层面来评价模型的优劣，从而使模型的构建者更加的全面的了解模型的性能，同时依据任务的偏向和要求来对模型进行取舍。常用的分类模型的评价指标有准确率（*Accuracy*）、精确率（*Precision*）、召回率（*Recall*）、F1-Score（*F1*），在探究不同评价指标前，先定义一些计算这些上述指标的基本值。具体如下所示：

预测值为正例，记为 P（Positive）；预测值为反例，记为 N（Negative）；这里要**特别强调一点，所谓的正例是我们需要关注的类别即为正例，除正例以外的都为反例（例如猫狗分类中，要计算猫的分类精度，那么猫即为正例，狗即为反例，反之亦然）。**预测值与真实值相同，记为 T（True）；预测值与真实值相反，记为 F（False）。

TP（True positives）：实际为正例，且被分类器划分为正例的实例数；

FP（False positives）：实际为负例，但被分类器划分为正例的实例数；

FN（False negatives）：实际为正例，但被分类器划分为负例的实例数；

TN（True negatives）：实际为负例，但被分类器划分为负例的实例数；

对应参数的定义：

准确率（*Accuracy*）

预测正确的样本数量占总量的百分比，具体的公式如下：

$$准确率（Accuracy）=\frac{TP+TN}{TP+TN+FP+FN}$$

精确率（*Precision*）

指分类正确的正样本个数（TP）占分类器判定为正样本的样本个数（$TP+FP$）的比例，精确率又称查准率，通俗的讲就是在分类器判定为正例的结果中有多少正确的正样本。具体的公式如下：

$$精确率\ （Precision）=\frac{TP}{TP+FP}$$

召回率（*Recall*）

召回率是指分类正确的正样本个数（TP）占真正的正样本个数（$TP+FN$）的比例。召回率又称查全率，通俗的讲就是正确的样本中有多少被找到，具体的公式如下：

$$召回率\ （Recall）=\frac{TP}{TP+FN}$$

***F1-Score*（$F1$）**

就是精确率和召回率的调和平均值。F1 分数认为召回率和精度同等重要,一些多分类问题的机器学习竞赛，常常将 F1-score 作为最终测评的方法。它是精确率和召回率的调和平均数，最大为 1，最小为 0。计算公式如下：

$$F1=\frac{2TP}{2TP+FP+FN}=2\cdot\frac{Precision\times Recall}{Precision+Recall}$$

案例：

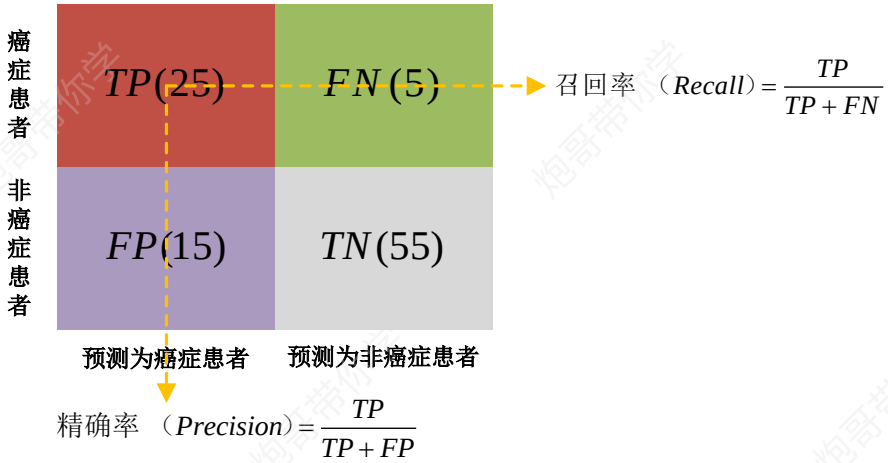
二分类的案例

现在有一个模型对人的体检指标进行是否有肿瘤的判断，这很显然是一个二分类的任务，结果只有是和否两种。假设现在有 100 个人，其中有 30 个人是患有肿瘤的，70 个人是健康的；现在利用模型对这 100 个人是否患有肿瘤的进行判断，最后的判断结果为有 40 个人患有肿瘤，60 个人是健康的。对比真实的结果发现，40 个人被判断患有肿瘤的人中间有 15 人原本是健康的，而被判断为健康的 60 人中有 5 个人原本是患有肿瘤的。

上述的案例或许有点绕，现利用混淆矩阵来表达上述模型判断的结构较为直观。具体结果如下图所示(以癌症患者为关注对象，此时预测出的癌症患者为正例):



利用混淆矩阵就很容易计算出模型的精度率和召回率，有了精度和召回即可很容易计算出 F1。



依据上述的混淆矩阵的提示，即可以计算出对应的评价指标:

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} = \frac{25+55}{25+55+15+5} = 80\%$$

$$Precision = \frac{TP}{TP+FP} = \frac{25}{25+15} = 62.5\%$$

$$Recall = \frac{TP}{TP+FN} = \frac{25}{25+5} = 83.33\%$$

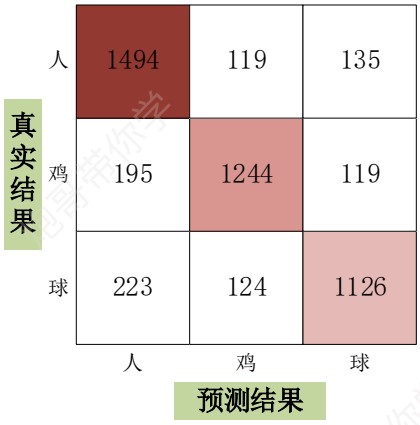
$$F1 = \frac{2TP}{2TP+FP+FN} = \frac{2\times 25}{2\times 25+15+5} = 71.43\%$$

从计算的结果来看，在癌症检测的场景中，我们往往希望检测所有患有癌症的人都检测到，哪怕有几个没有患有癌症的人被误检测为癌症，在后续的筛查的时候这样的结果也会被勘误，如果模型将患有癌症的人检测为未患有癌症，那么这将会是一个较大的医疗事故，对患者的影响极大。因此在这样的场景中我们希望召回率较大，尽可能为 1，就是所有的患有癌症的人都被找到了。

多分类的案例

在实际应用中，往往更多的任务为多分类任务，为了加深对评价指标的概念的理解，利用一个多分类的案例来进行评价指标的计算。

现有一个分类任务，对图片中的人、鸡、球进行分类，共有每个图片中只有一个类型的物体，其中人的图片有 1748、鸡的图片有 1558、球的图片有 1473。其中含有人的图片中有 1494 个图被正确分类，有 119 个图被分为鸡，135 个图被分为球；含有鸡的图片中有 1244 个图被正确分类，有 195 个图被分为人，119 个图被分为球；含有球的图片中有 1126 个图被正确分类，有 223 个图被分为人，124 个图被分为鸡。同样利用混淆矩阵可以更加清晰的看出模型的分类结果。



按上述案例计算结果的

$$Accuracy=\frac{1494+1244+1126}{1748+1558+1473}=80.85\%$$

人为正例的分类结果

$$Precision=\frac{TP}{TP+FP}=\frac{1494}{1494+(195+223)}=78.13\%$$

$$Recall=\frac{TP}{TP+FN}=\frac{1494}{1494+(119+135)}=85.46\%$$

$$F1=2\cdot\frac{Precision\times Recall}{Precision+Recall}=2\cdot\frac{78.13\%\times 85.46\%}{78.13\%+85.46\%}=81.63\%$$

鸡为正例的分类结果

$$Precision=\frac{TP}{TP+FP}=\frac{1244}{1244+(119+124)}=83.65\%$$

$$Recall = \frac{TP}{TP + FN} = \frac{1244}{1244 + (195 + 119)} = 78.56\%$$

$$F1 = 2 \cdot \frac{Precision \times Recall}{Precision + Recall} = 2 \cdot \frac{83.65\% \times 78.56\%}{83.65\% + 78.56\%} = 81.03\%$$

球为正例的分类结果

$$Precision = \frac{TP}{TP + FP} = \frac{1126}{1126 + (135 + 119)} = 81.59\%$$

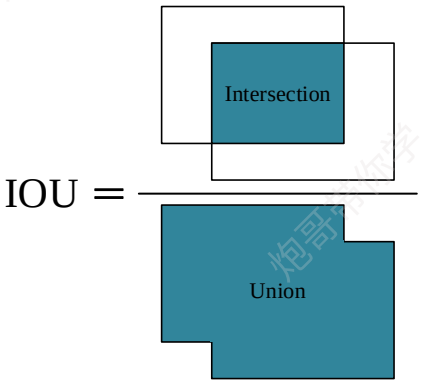
$$Recall = \frac{TP}{TP + FN} = \frac{1126}{1126 + (223 + 124)} = 76.44\%$$

$$F1 = 2 \cdot \frac{Precision \times Recall}{Precision + Recall} = 2 \cdot \frac{81.59\% \times 76.44\%}{81.59\% + 76.44\%} = 78.93\%$$

交并比 IOU

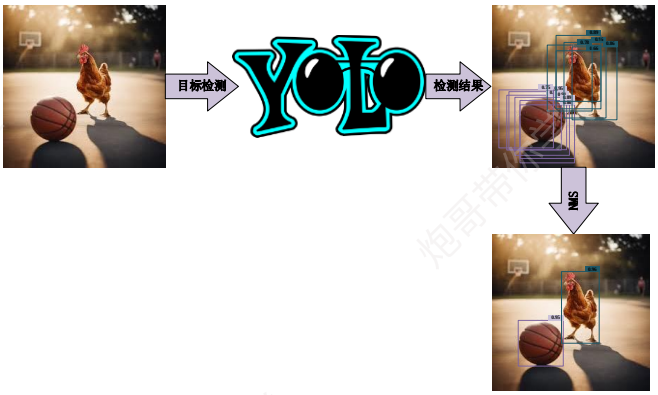
IOU 的全称为交并比（Intersection Over Union），通过这个名称我们大概可以猜到 IOU 的计算方法。IOU 计算的是“预测的边框”和“真实的边框”的交集和并集的比值。

在目标检测任务中，IOU 用于匹配预测的边界框（bounding box）和真实的边界框。通过计算两者之间的 IOU，可以判断预测是否正确地检测到了目标。同时在非极大值抑制计算中 IOU 作为其中的重要指标。



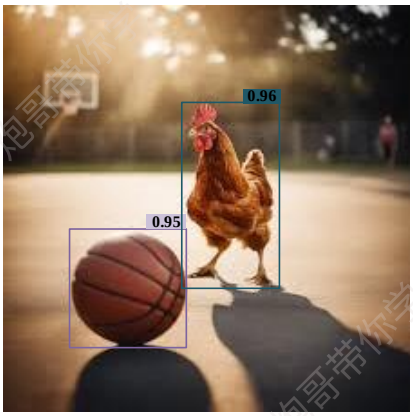
置信度与非极大值抑制 NMS

Yolo 系列的目标检测的结果是包含矩形框、类别和置信度，其结果经过非极大值抑制（NMS）筛选后输出的结果才是我们需要的结果。具体的示意图如图所示。



Yolo 置信度

Yolo 模型的输出中包含置信度这一项，置信度得分可以有效的帮助我们筛选检测较差的结果。如图中检测到 bounding box 中的右上角的数值即为置信度得分。置信的得分是一个 0-1 之间的数值。



很多同学会认为置信度就是该物体的概率值，例如图中的蓝色框中的置信度代表检测到鸡的概率，紫色框中的置信度代表检测到篮球的概率。但是这样的答案是片面的。

在原始论文中，作者提到了两种情况下的置信度，一种是是否有物体的置信度，另一种是在有物体的情况下，检测的不同类别物体的置信度，这两种是递进的关系，而我们模型的输出即为类别置信度。

置信度作用定义有两重：

1、代表当前 box 是否有对象的概率 $\Pr(\text{Object})$，这个概率值为 1 或者 0，**注意**，这里是对象，不是某个类别的对象，也就是说它用来说明当前 box 内只是个背景（backgroud）还是有某个物体（对象）；

2、表示当前的 box 有对象时，它自己预测的 box 与物体真实的 box 之间的 IOU 交并比，**注意：**这里所说的物体真实的 box 实际是不存在的，这只是模型表达自己框出了物体的自信程度。

因此此时置信度的公式为：

$$C = \Pr(\text{Object}) * \text{IOU}_{\text{pred}}^{\text{truth}}$$

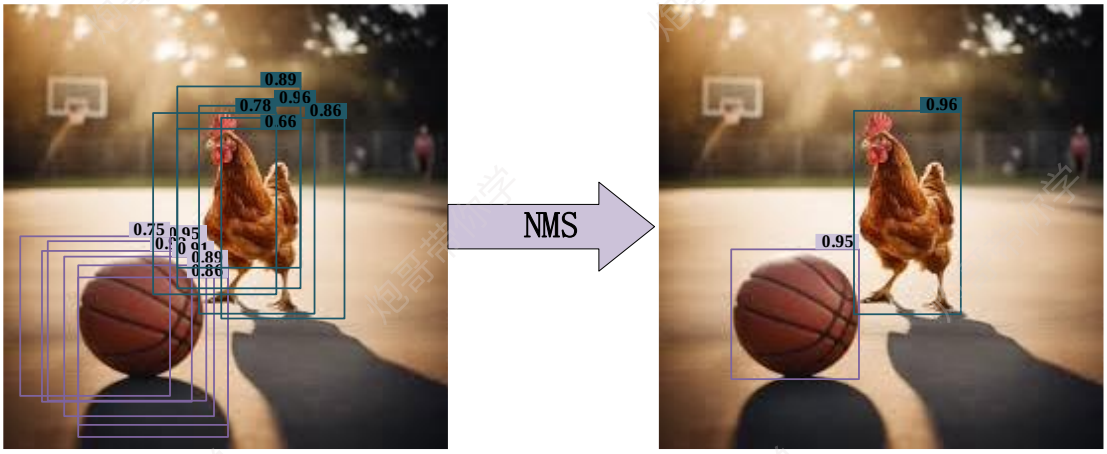
而类别置信度，是在有物体的情况下，对应类别的物体的置信度，其公式为：

$$C = \Pr\left(\text{Class}_i \middle| \text{Object}\right) * \Pr(\text{Object}) * \text{IOU}_{\text{pred}}^{\text{truth}} = \Pr(\text{Class}_i) * \text{IOU}_{\text{pred}}^{\text{truth}}$$

以上所述，也就不难理解作者为什么将其称之为置信度了，因为不管哪重含义，都表示一种自信程度：框出的 box 内确实有物体和物体类型的自信程度和框出的 box 将整个物体的所有特征都包括进来的自信程度。

NMS 算法流程：

如图所示，利用 Yolo 系列的目标检测算法对图像中的鸡和篮球进行检测，如果不经过 NMS 算法对其进行矩形框去重，可以发现一个目标会有多个矩形框。这是由于 Yolo 系列算法会针对输出图片的规定区域输出多个预测框，同时 yolov3 以上的算法往往具有多个检测头。因此需要利用 NMS 算法将最合适的目标检测框保留，其余的检测框去除。



NMS 是针对不同类别检测框独立且并行处理，以篮球检测为例，NMS 算法流程：

1、选取篮球检测 box 中的置信度最大的那一个 box，记为 box_best,并保留它。

2、计算 box_best 与其余篮球检测的 box 的 IOU。在计算该步骤之前，需要设置一个 IOU 的阈值，该阈值往往设为 0.5。

3、如果 IOU>0.5，那么就舍弃这个 box（由于可能两个 box 表示同一目标，所以保留分数高的那一个）。

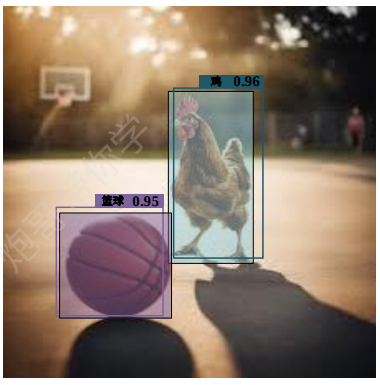
4、从最后剩余的 boxes 中，再找到最大置信度的那一个，如此循环往复。

目标检测中的评价指标计算

前面已经很详细的讲解了在分类的场景下的精确率、召回率指标的计算，同时也详细的讲解了置信度和 NMS 算法，yolo 系列的目标检测算法最后的结果输出依赖于置信度和 NMS 算法。不同的置信度阈值和 IOU 阈值输出的结果往往是不同的。

目标检测的检测结果是一个带有类别的矩形框，那么如果要判断一个目标是否检测到，那就要看这个目标的 bounding box 是否将物体框住，同时该检测框的类别对不对。

类别对不对这个比较好理解，但是是否将物体框住这个就比较主观了，因此往往利用 IOU 阈值来确定 bounding box 是否将物体框住。一般设置的 IOU 阈值为 0.5，大于 0.5 即为框住。具体如下图所示：



如图所示，蓝色阴影部分为鸡的标注的矩形框，紫色的阴影部分为篮球的标注的矩形框，很显然，图中的检测到的鸡的矩形框和鸡的标注框 IOU 阈值大于 0.5，检测到的篮球的矩形框和篮球的标注框 IOU 阈值也很显然大于 0.5（计算指标的时候是需要严格计算的，而不是人为看的），这说明图中的篮球和鸡都被检测到了。

计算目标检测中的评价指标，首先需要定义 TP、FP、FN。这里需要声明一下，每一组 TP、FP、FN 都是在某个 IOU 阈值和置信度阈值下来讨论的，我们设定下面的案例中的

IOU 阈值为 0.5，置信度阈值为 0.5。

以检测篮球为正例（此时只关注篮球，其他类别不关注）。

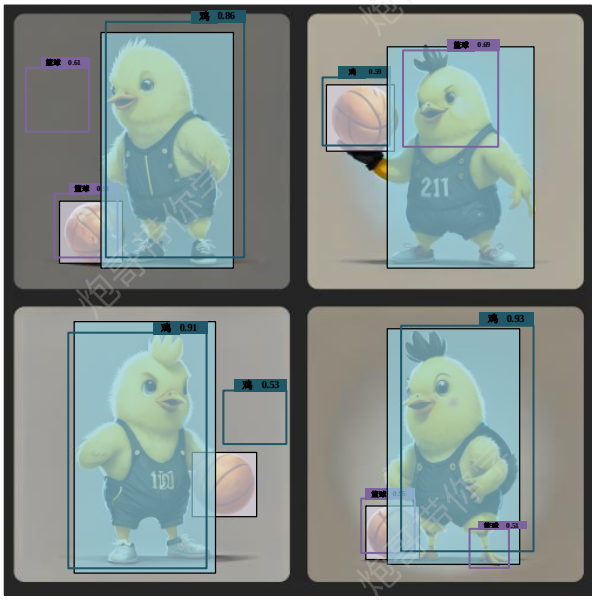


从图中可以看出，图中的 4 个篮球的检测框和标注框计算的 IOU 值都大于 0.5（**注意：检测框上面的数值是置信度不是 IOU 值，这里我们只是默认我们计算过 IOU 值了**）。

那么此时 TP=4、FP=0、FN=0。很显然此时关注到的目标已经全部检测到。

上述为最理想的情况下，我们关注的目标全部已经检测到了，如果在一个检测不理想的情况下怎么确定 FP 和 FN 呢？

FP 的意思是错误的正类，顾名思义就是将一个原本不是我们关注的目标检测成我们关注的目标；FN 的意思是错误的反类，顾名思义就是将一个我们关注的目标检测为错误检测为反例，这里需要注意的是漏检的也属于 FN 中，本质上漏检就是将我们关注的目标检测为背景因此不显示出来。因此我们观察下图



如上图所示：

如果是将篮球检测作为正例，那么：

图中真正检测到的篮球有 2 个，因此 TP=2。图中有一个背景、鸡头、还有鸡爪检测为篮球，这很显然是错误检测，因此 FP=3。图中有一个篮球漏检测，一个篮球错误检测为鸡类别，因此 FN=2。

篮球检测为正例的检测结果

$$Precision = \frac{TP}{TP+FP} = \frac{2}{2+3} = \frac{2}{5}$$

$$Recall = \frac{TP}{TP+FN} = \frac{2}{2+2} = \frac{1}{2}$$

如果是将鸡检测作为正例，那么：

图中真正检测到的鸡有 3 个，因此 TP=3。图中有一个背景和篮球检测为鸡，这很显然是错误检测，因此 FP=2。图中有一个鸡漏检测，因此 FN=1。

鸡检测为正例的检测结果

$$Precision = \frac{TP}{TP+FP} = \frac{3}{3+2} = \frac{3}{5}$$

$$Recall = \frac{TP}{TP+FN} = \frac{3}{3+1} = \frac{3}{4}$$

PR 曲线和 AP（Average-Precision）

PR 曲线

前面也已经强调了不同的 IOU 阈值和置信度阈值可以得出不同的 TP、FP、FN。那么即可以得出不同的召回率和精确度，由此就可以绘制出 PR 曲线，同时计算出 AP 评价指标和 MAP 评价指标。

下面来看一个案例：

首先固定 IOU 的值为 0.5，利用一个网络来检测多张图像中的人、球、鸡这三种目标。已知，这多张图中一共有 10 个人、8 个球、7 只鸡；通过网络的检测，输出如下

IOU=0.5					
置信度	结果对错	置信度	结果对错	置信度	结果对错
人（GT10个）		球（GT8个）		鸡（GT7个）	
0.99	对	0.99	对	0.99	错
0.95	对	0.93	错	0.83	对
0.91	错	0.87	错	0.67	对
0.87	对	0.81	对	0.51	错
0.83	对	0.75	对	0.35	对
0.79	错	0.69	错	0.19	对
0.75	对	0.63	对	0.03	错
0.71	对	0.57	对		
0.67	错	0.51	错		
0.53	对	0.45	对		
0.49	对	0.39	错		
0.35	错	0.33	错		
0.13	错	0.27	错		
0.01	错	0.21	错		
		0.15	对		
		0.09	错		
		0.03	错		

以检测人为例，计算不同置信度下的 TP、FP、FN+TP(这里声明一下为什么要计算的是 TP+FN，本质上 TP+FN 就是样本中正类的数量，如果只看人这个类别的检测结果的时候，FN 包含漏检和将正类错误检测为反类的目标，那么只关注检测到的正类的结果话，其中错误检测为反类的目标就显示不出来，因此我们用 TP+FN 来表示样本中正类的数量，这样即可计算召回率)。在目标检测中小于置信度阈值的检测框都会被过滤掉，其中就可能包含正确的检测框，这就会导致检测框的漏检。

首先，我们要计算出每个置信度下的 TP 和 FP，以及 TP+FN，计算过程，当我们只看

第一个置信度最高的检测结果的时候，结果如下，计算出一组 P，R。

IOU=0.5						
人（GT10个）						
置信度	结果对错	TP	FP	FN+TP	精度	召回
0.99	对	1	0	10	1	0.1
0.95	对					
0.91	错					
0.87	对					
0.83	对					
0.79	错					
0.75	对					
0.71	对					
0.67	错					
0.53	对					
0.49	对					
0.35	错					
0.13	错					
0.01	错					

当我们把置信度拉到 0.95，只看前两个计算结果的时候，计算出一组 P，R

IOU=0.5						
人（GT10个）						
置信度	结果对错	TP	FP	FN+TP	精度	召回
0.99	对	1	0	10	1	0.1
0.95	对	2	0	10	1	0.2
0.91	错					
0.87	对					
0.83	对					
0.79	错					
0.75	对					
0.71	对					
0.67	错					
0.53	对					
0.49	对					
0.35	错					
0.13	错					
0.01	错					

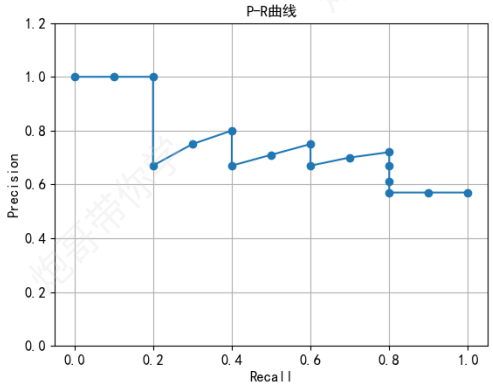
当我们把置信度拉到 0.91，只看前 3 个计算结果的时候，计算出一组 P，R

IOU=0.5						
人（GT10个）						
置信度	结果对错	TP	FP	FN+TP	精度	召回
0.99	对	1	0	10	1	0.1
0.95	对	2	0	10	1	0.2
0.91	错	2	1	10	0.666667	0.2
0.87	对					
0.83	对					
0.79	错					
0.75	对					
0.71	对					
0.67	错					
0.53	对					
0.49	对					
0.35	错					
0.13	错					
0.01	错					

以此类推，我们计算出在所有置信度下的所有 P，R 值

IOU=0.5						
人（GT10个）						
置信度	结果对错	TP	FP	FN+TP	精度	召回
0.99	对	1	0	10	1	0.1
0.95	对	2	0	10	1	0.2
0.91	错	2	1	10	0.666667	0.2
0.87	对	3	1	10	0.75	0.3
0.83	对	4	1	10	0.8	0.4
0.79	错	4	2	10	0.666667	0.4
0.75	对	5	2	10	0.714286	0.5
0.71	对	6	2	10	0.75	0.6
0.67	错	6	3	10	0.666667	0.6
0.53	对	7	3	10	0.7	0.7
0.49	对	8	3	10	0.727273	0.8
0.35	错	8	4	10	0.666667	0.8
0.13	错	8	5	10	0.615385	0.8
0.01	错	8	6	10	0.571429	0.8

然后将 Recall 作为横轴，Precision 作为纵轴画图，这样，我们就画出了在 IOU0.5 下模型检测人的 P-R 曲线。



AP(等价于 AUC_{PR})

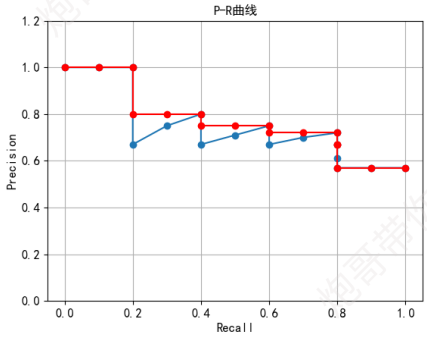
有了 P-R 曲线,要计算 AP(Average Precision)直接求 P-R 曲线下的面积就行了,通常来说就是一个积分:

$$AP = \int_0^1 p(r)\mathrm{d}r$$

但是，一般我们不直接去这么算,会简化一下，求个近似:

$$p_{\text{interp}}(r) = \max_{\tilde{r} \geq r} p(\tilde{r})$$

此时绘制的图像就转化为如图所示。



PASCAL VOC 竞赛定义:

在 IOU 阈值为 0.5 的前提条件下

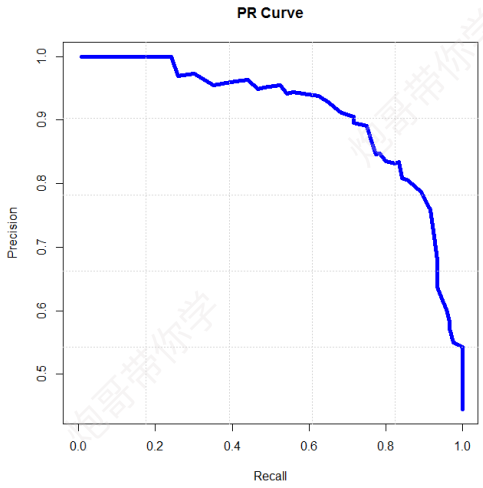
AP 值（2010 年前）：PASCAL VOC 竞赛定义：recall 的值从 0 到 1 划分为 11 份（0，0.1，……，0.9，1.0），利用公式 $p_{\text{interp}}(r)=\max_{\tilde{r}\geq r}p(\tilde{r})$ 计算准确率的最大值，然后再计算这些准确率最大值的综合并平均。

在我们这个例子中，最终人检测的 AP 值：

$$AP=(1+1+1+0.8+0.8+0.75+0.75+0.72+0.72+0.57+0.57)/11=0.789$$

AP 值（2010 年后）：11 份 recall 换成了 PR 曲线中的所有 recall 数据点。recall 都计算一下 $p_{\text{interp}}(r)$，然后在相加求平均。

典型的 PR 曲线图如图所示：



mAP(mean average precision)，这个就很清晰了，就是计算不同的类型的 AP 值后进行平均值计算即可计算出 mAP，如本文中的案例，计算人、鸡、球的检测结果的 AP 值后再除以 3 后就能得到 mAP 值。

COCO 竞赛定义：

coco 的 AP 和 mAP 是一个概念，都是跨类别的求平均，非但如此，coco 中的 AP 还使用了不同的 10 个 IOU 得到的结果进行了平均，IOU 取值范围 0.5 到 0.95，取值间隔 0.05. 所以无需纠结到底是 AP 还是 mAP，最终还是要看具体的实现是怎样。

模型的检测速度

检测速度，这个很好理解，简单的说就是一秒钟能够检测多少张图片。不同的目标检测技术往往会有不同的 mAP 和检测速度，如下图（后面我们将逐一学习）：

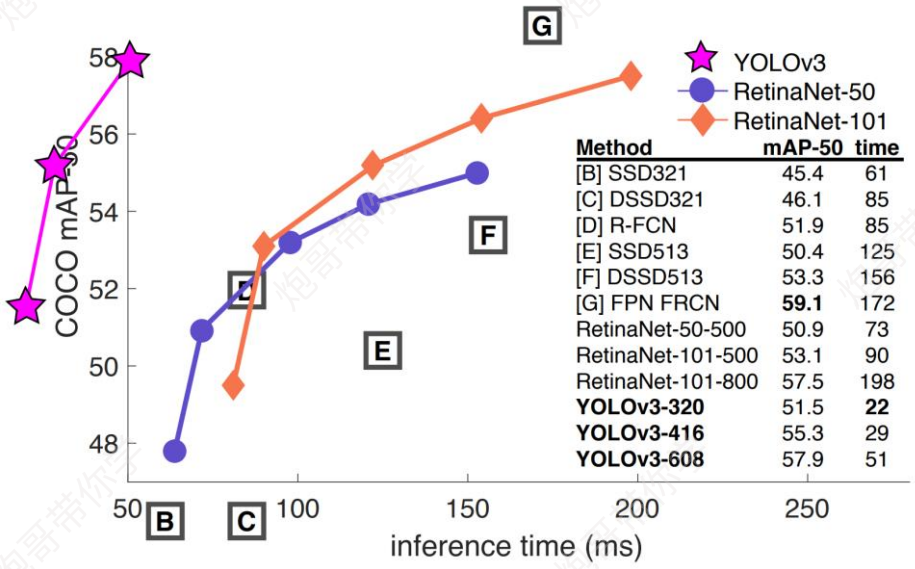
Yolov1 中作者做的对比表格

Real-Time Detectors	Train	mAP	FPS
100Hz DPM [31]	2007	16.0	100
30Hz DPM [31]	2007	26.1	30
Fast YOLO	2007+2012	52.7	**155**
YOLO	2007+2012	**63.4**	45
Less Than Real-Time			
Fastest DPM [38]	2007	30.4	15
R-CNN Minus R [20]	2007	53.5	6
Fast R-CNN [14]	2007+2012	70.0	0.5
Faster R-CNN VGG-16[28]	2007+2012	73.2	7
Faster R-CNN ZF [28]	2007+2012	62.1	18
YOLO VGG-16	2007+2012	66.4	21

Yolov2 中作者做的对比表格

Detection Frameworks	Train	mAP	FPS
Fast R-CNN [5]	2007+2012	70.0	0.5
Faster R-CNN VGG-16[15]	2007+2012	73.2	7
Faster R-CNN ResNet[6]	2007+2012	76.4	5
YOLO [14]	2007+2012	63.4	45
SSD300 [11]	2007+2012	74.3	46
SSD500 [11]	2007+2012	76.8	19
YOLOv2 288×288	2007+2012	69.0	91
YOLOv2 352×352	2007+2012	73.7	81
YOLOv2 416×416	2007+2012	76.8	67
YOLOv2 480×480	2007+2012	77.8	59
YOLOv2 544×544	2007+2012	**78.6**	40

Yolov3 中作者做的对比表格



Method	mAP-50	time
[B] SSD321	45.4	61
[C] DSSD321	46.1	85
[D] R-FCN	51.9	85
[E] SSD513	50.4	125
[F] DSSD513	53.3	156
[G] FPN FRCN	**59.1**	172
RetinaNet-50-500	50.9	73
RetinaNet-101-500	53.1	90
RetinaNet-101-800	57.5	198
YOLOv3-320	51.5	**22**
YOLOv3-416	55.3	29
YOLOv3-608	57.9	51